Tesina Progetto
Sistemi Informativi e Web Semantico

PPRL: PRIMAT Tool

Di
Mario Cristiano

Indice

1. Introduzione su Record Linkage

Il record linkage mira a collegare i record provenienti da differenti fonti di dati che però si riferiscono alla stessa entità del mondo reale. Di solito, quando possibile, nel mapping tra i record, si usano gli identificatori diretti (globali), come, ad esempio, un numero di identificazione personale.
In generale, però, mancano gli identificatori globali per mappare direttamente i record, quindi il collegamento può essere ottenuto solo confrontando i quasi-identificatori (quasi-identifiers) disponibili, come il nome, l'indirizzo o la data di nascita. Questi identificatori potrebbero non essere unici, potrebbero cambiare nel tempo, e potrebbero avere delle differenze di implementazione nelle singole basi di dati. Quindi, se il record linkage si basasse solo su un matching esatto tra i quasi-identificatori potrebbe esserci un numero elevato di falsi positivi.
Tuttavia, in molti casi, i data owners sono disposti / autorizzati a fornire i loro dati per tale integrazione solo se vi è una sufficiente protezione delle informazioni sensibili per garantire la privacy delle persone (come i pazienti di un ospedale o i clienti di una struttura).
Ad esempio, nella ricerca medica, i dati di diverse fonti (ad esempio, i dati provenienti da diversi ospedali) devono essere abbinati per studiare eventuali correlazioni tra alcune malattie senza rivelare l'identità dei singoli pazienti.
In molti casi, invece, i dati devono essere protetti per legge, al fine di garantire l'anonimato dei vari soggetti.

2. Cos'è il PPRL

Il Privacy Preserving Record Linkage (PPRL) affronta questo problema fornendo tecniche per abbinare i vari record, preservando la loro privacy e consentendo la combinazione di dati provenienti da fonti diverse per migliorare l'analisi dei dati e la ricerca.
A tal fine, il collegamento dei record relativi alle persone si basa su valori codificati dei quasi-identificatori e i dati necessari per l'analisi (ad esempio, i dati sanitari) sono separati da questi quasi-identificatori. Perciò, i dati rilevanti possono essere forniti a un ricercatore senza i dati identificativi.
Questi approcci PPRL possono essere applicati in molti settori, come la sorveglianza della salute pubblica, gli studi demografici e le analisi di marketing.
Il PPRL deve, quindi, affrontare diverse sfide:

- è necessario garantire un elevato grado di privacy attraverso un'adeguata codifica dei dati sensibili, e l'uso di un'unità di collegamento fidata tra le parti (trusted linkage unit).
- il PPRL deve raggiungere un'elevata qualità di collegamento, evitando false o mancate corrispondenze (FP, FN).
- è necessaria un'elevata efficienza, con tempi di linkage rapidi, e una buona scalabilità con grandi volumi di dati. Un problema principale per le prestazioni è la complessità quadratica

del record linkage, quando ogni record della prima fonte viene confrontato con ogni record della seconda fonte. Per una maggiore efficienza, il numero di confronti può essere ridotto adottando approcci di blocco o di filtraggio. Inoltre, il matching può essere eseguito in parallelo su più nodi di elaborazione.

3. Tool PRIMAT

3.1 Introduzione

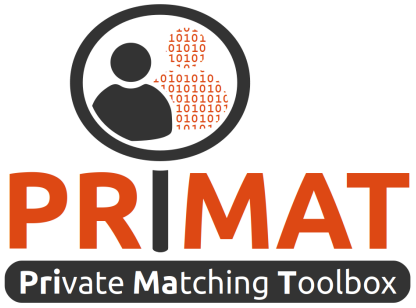

PRIMAT (Private Matching Toolbox) è uno strumento open source flessibile e scalabile, scritto in Java, sviluppato dal "Database Group" dell'università di Leipzig in Germania, che permette l'applicazione di flussi di PPRL, nonché la valutazione comparativa di diversi metodi PPRL. PRIMAT si occupa di identificare record in diversi database che si riferiscono alla stessa persona, garantendo scalabilità fino a milioni di record, e di proteggere le informazioni personali, garantendo la privacy e riducendo al minimo il rischio di divulgazione di informazioni sensibili. Questo strumento trova applicazioni in diversi settori, tra cui la sanità, la sicurezza degli stati, le analisi di marketing, garantendo alta affidabilità e qualità nel processo.

L'integrazione di dati personali è necessaria in molte applicazioni. Tuttavia, i requisiti legali più severi in materia di protezione dei dati richiedono che sempre più spesso che la data integration rispetti la privacy e che non riveli l'identità delle persone per le quali i dati vengono combinati e analizzati. Questi requisiti sono soddisfatti dalle tecniche di Privacy-Preserving Record Linkage (PPRL) che codificano gli attributi identificativi, ad esempio il nome e la data di nascita, ed eseguono il linkage dei record codificati in un ambiente separato e fidato. Negli ultimi anni sono stati proposti un enorme numero di metodi per il PPRL. Ma, nonostante il gran numero di proposte, il loro uso pratico nelle applicazioni reali è ancora limitato a causa dell'assenza di strumenti convenienti e dell'elevata complessità nel selezionare un approccio PPRL adeguato. Sebbene esistano alcune implementazioni e prototipi di PPRL, essi si concentrano spesso più su aspetti di ricerca e non forniscono sufficienti funzionalità per l'utilizzo pratico.
È necessaria, quindi, la presenza di uno strumento facile da usare, intuitivo, affidabile e open source, per facilitare l'adozione del PPRL nelle applicazioni reali. PRIMAT fornisce differenti componenti, protocolli, modalità di linkage, e framework per la valutazione, in termini di affidabilità ed efficienza, dei diversi metodi di PPRL.

Il PPRL presenta, in particolare, tre sfide fondamentali che devono essere affrontate:

- è necessario garantire un elevato grado di privacy fornendo tecniche di codifica all'avanguardia che riducano il rischio di violazione dei dati.

- è necessario raggiungere un'elevata qualità di linkage, ossia ridurre al minimo il numero di corrispondenze false (FP - False Positive) e mancanti.
- il PPRL deve essere scalabile per grandi volumi di dati, fino a milioni di record. Per questo scopo tornano utili metodi di filtraggio e metodi di elaborazione a blocchi, distribuita e parallela.

Tipicamente il PPRL viene eseguito in batch mode, dove il linkage dei record viene eseguito in gruppi di record. Tuttavia, può essere necessario effettuare il linkage in maniera continua (incrementale), senza per forza ripetere il linkage dei record già processati.
Nel PPRL è essenziale supportare anche approcci multy-party, con due o più data owners. In questi casi non deve esserci solo un linkage dei record, ma essi devono anche essere raggruppati in cluster, in maniera tale che tutti i record in un cluster corrispondano tra loro.

3.2 Altre tecniche di PPRL

Gli approcci più recenti riguardo il PPRL si basano per lo più su tecniche di codifica basate su *Bloom-filter*, che sfruttano trusted linkage unit centralizzate che eseguono il linkage dei record codificati. Questa tecnica è basata su un vettore di bit, inizialmente inizializzati a zero, e su un insieme di funzioni di hash. Ogni funzione hash viene applicata a ogni attributo del record e restituisce un indice all'interno del vettore di bit. Infine, i bit in queste posizioni dell'indice vengono impostati a uno.
Recentemente sono stati sviluppati anche altri tool, tutti con delle inefficienze nell'implementazione del flusso di PPRL: *MergeToolBox*, che però fornisce un supporto limitato al linkage dei record; *Mainzel-liste*, che però non supporta l'elaborazione a blocchi e le attuali tecniche di codifica che tutelano la privacy, peccando, quindi, in scalabilità e protezione dei dati; *SOEMPI*, tool che, però, non supporta metodi di evaluation e non è ottimizzato per il linkage incrementale; *LSHDB*, che non supporta a pieno il clustering dei record.

3.3 Descrizione di PRIMAT

Si distinguono due ruoli nel processo di PPRL: Database Owners (DOs) e Trusted third parties.
I Database Owners gestiscono i record con i dati sensibili di cui poi dovrà essere fatto il linkage, mentre le terze parti fidate effettuano il linkage vero e proprio. Nel caso di PRIMAT, esiste una Trusted Linkage Unit (LU) che effettua il linkage dei record codificati forniti dai DOs.

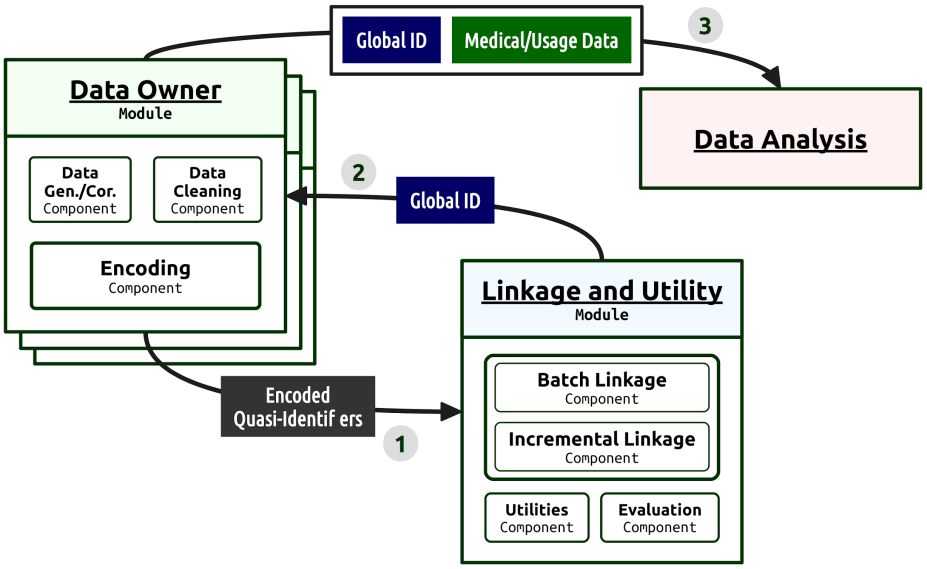

Ogni processo di PPRL consiste in 3 step:

1. Ogni Database Owner prepara i record per il linkage e codifica gli attributi identificativi di ogni entità, i quali poi vengono mandati alla Linkage Unit.
2. La Linkage Unit esegue il linkage dei record e restituisce i global ID ai Database Owners. Pertanto, ogni coppia di record che ha lo stesso ID globale viene considerata come una corrispondenza.
3. I dati ottenuti possono essere combinati per ulteriori Data Analysis.

In PRIMAT esistono, quindi, due moduli:

- DO Module: usato per fare pre-processing e codifica dei record del database per preparare i record al linkage.
- Linkage and Utility Module: fornisce varie tecniche, metodi e procedure per effettuare il linkage dei record.

Nella tabella sottostante sono riportate le funzionalità di PRIMAT già implementate e quelle pianificate per futuri aggiornamenti.

Comp.	Function / Feature	Status
D_1	Data generation	Implemented
	Data corruption	Planned
D_2	Split/merge/remove attributes	Implemented
	Replace/remove unwanted values and stopwords	Implemented
	OCR transformation	Implemented
	Intra-source record linkage	Planned
D_3	Bloom filter encoding and hardening techniques	Implemented
	Client-side standard blocking	Implemented
$D_1 - D_3$	Graphic user interface	Planned
L_1	Pre-processing templates	Planned
	Private schema matching	Planned
L_2	Standard & LSH-based blocking; metric space filtering	Implemented
	Threshold-based classification	Implemented
	Post-processing	Implemented
	Multi-threaded processing	Implemented
	Distributed processing	Planned
	Multi-party support	Planned
L_3	Incremental linkage	Planned
L_4	Quality & scalability evaluation	Implemented
	Privacy-preserving match result visualization	Planned

Data Generation and Corruption (D1): componente che consente di generare dataset sintetici realistici, possibilmente basati su dati reali, che possono essere utilizzati per analizzare i flussi di PPRL.

Data Cleaning (D2): componente che consente di effettuare pre-processing sui record, e, in particolare, operazioni di cleaning e standardizzazione dei dati.

Data Encoding (D3): gli attributi identificativi di ogni record vengono codificati (utilizzando tecniche di codifica basate su Bloom-Filter).

Utilities (L1): componente che fornisce metodi per preparare i dati per il linkage.

Batch Linkage (L2): è il componente principale della Linkage Unit. Esso implementa diverse tecniche di linkage. In particolare, per ridurre la complessità del linkage vengono forniti approcci di blocking standard e basati su LSH, e approcci di filtraggio. Per la classificazione vengono usate misure di similarità come la Jaccard o la Dice similarity. Sono inclusi, inoltre, metodi di post-processing, che vanno a migliorare la qualità del linkage, selezionando i migliori match candidates se ci sono più record che eccedono una determinata soglia di similarità.

Incremental Linkage (L3): fornisce supporto per memorizzare e recuperare risultati di match precedenti, rendendo possibile il linkage incrementale.

Evaluation Tool (L4): fornisce metodi per valutare il flusso di PPRL, fornendo, ad esempio, metriche di qualità come precision, recall e F-measure.

4. Esempi di funzionamento con PRIMAT

4.1 Codice di esempio PRIMAT

4.1.1 DataOwners Function

```
public static void DataOwners(String inputhPathName, String partyName) throws IOException {

 // Dataset Reading

final NamedRecordSchemaConfiguration rsc = new NamedRecordSchemaConfiguration.Builder()
          .add(0, NonQidAttributeType.ID)
          .add(1, NonQidAttributeType.PARTY)
          .add(2, QidAttributeType.STRING, "fname")
          .add(3, QidAttributeType.STRING, "gname")
          .add(4, QidAttributeType.STRING, "address")
          .add(5, QidAttributeType.STRING, "dob")
          .build();

        final String inputPath = inputhPathName + ".csv";
        final String outputPath = inputhPathName + "_encoded.csv";

        final DatasetReader reader = new DatasetReader(inputPath, true, rsc);
        final List < Record > records = reader.read();


        // Data Cleaning

        final PartySupplier partySupp = new PartySupplier();
        partySupp.preprocess(records);

        final SplitDefinition splitDef = new SplitDefinition();
        splitDef.setSplitter("address", new BlankSplitter(2));
        splitDef.setSplitter("dob", new DotSplitter(3));

        final FieldSplitter fs = new FieldSplitter(splitDef);
        fs.preprocess(records);

        final NormalizerChain normChain = new NormalizerChain(
          List.of(new UmlautNormalizer(), new TrimNormalizer(), new LowerCaseNormalizer(), new
       AccentRemover(),
            new SpecialCharacterRemover(), new SubstringNormalizer(0, 12)));

        final NormalizerChain numberNorm = new NormalizerChain(new
       LetterLowerCaseToNumberNormalizer(),
          new LetterUpperCaseToNumberNormalizer());

        final NormalizeDefinition normDef = new NormalizeDefinition();
        normDef.setNormalizer(0, normChain);
        normDef.setNormalizer(1, normChain);
        normDef.setNormalizer(2, numberNorm);
        normDef.setNormalizer(3, normChain);
        normDef.setNormalizer(4, numberNorm);
        normDef.setNormalizer(5, numberNorm);
        normDef.setNormalizer(6, numberNorm);

        final FieldNormalizer fn = new FieldNormalizer(normDef);
        fn.preprocess(records);


        // Encoding
```

```
        final FeatureExtractor featEx = new BigramExtractor(true);
        final int k = 10;

        final BloomFilterExtractorDefinition exDef = new BloomFilterExtractorDefinition();
        exDef.setColumns(0, 1, 2, 3, 4, 5, 6);
        exDef.setExtractors(featEx);
        exDef.setNumberOfHashFunctions(k);

        final HashingMethod hashing = new RandomHashing(1024, RandomFactory.SECURE_RANDOM);

        final BloomFilterDefinition def1 = new BloomFilterDefinition();
        def1.setName("BS");
        def1.setBfLength(1024);
        def1.setHashingMethod(hashing);
        def1.setFeatureExtractors(List.of(exDef));
        def1.setHardener(new NoHardener());

        final Encoder encoder = new BloomFilterEncoder(List.of(def1));

        final List < Record > encodedRecords = encoder.encode(records);


        // Final dataset writing

        final CSVWriter csvWriter = new CSVWriter(outputPath);
        csvWriter.writeRecords(encodedRecords, encoder.getSchema());

}
```

4.1.2 Linkage Unit Function

```
public static void LinkageUnit(String inputhPathName) throws IOException {

        // Dataset Reading

        // Schema Configuration
        final NamedRecordSchemaConfiguration rsc = new NamedRecordSchemaConfiguration.Builder()
        .add(0, NonQidAttributeType.ID)
        .add(1, NonQidAttributeType.GLOBAL_ID)
        .add(2, NonQidAttributeType.PARTY)
        .add(3, QidAttributeType.BITSET, "BS")
        .build();

        System.out.println("#Named Record Schema Configuration rsc "
                + rsc.getNonQidAttributeMap()
                + rsc.getQidAttributeNameMap());

        // Parameters
        final double threshold = 0.8;
        final int matches = 20;

        final String namePartyA = "A";
        final String namePartyB = "B";

        // Read the dataset file
        final DatasetReader reader = new DatasetReader(inputhPathName, true, rsc);
        final List<Record> dataset = reader.read();
        System.out.println("#dataset " + dataset);

        // List the records for the 2 dataset A and B
        final List<Record> datasetA = dataset.stream()
                .filter(r ->
r.getPartyAttribute().getValue().getName().equals(namePartyA)).collect(Collectors.toList());
```

```
        System.out.println("#dataset A " + datasetA);

        final List<Record> datasetB = dataset.stream()
                .filter(r ->
r.getPartyAttribute().getValue().getName().equals(namePartyB)).collect(Collectors.toList());
        System.out.println("#dataset B " + datasetB);

        // Create input for the 2 dataset
        final Map<Party, Collection<Record>> input = new HashMap<>();
        input.put(new Party(namePartyA), datasetA);
        input.put(new Party(namePartyB), datasetB);
        System.out.println("#input " + input);

        System.out.println("#Records source " + namePartyA + ": " + datasetA.size());
        System.out.println("#Records source " + namePartyB + ": " + datasetB.size());

        final ComparisonStrategy compStrat = ComparisonStrategy.SOURCE_CONSISTENT;

        final LshKeyGenerator keyGen = new RandomHammingLshKeyGenerator(16, 30, 1024, 42L);
        final Blocker blocker = new LshBlocker(keyGen);

        final RecordSimilarityCalculator simCalc = new BaseRecordSimilarityCalculator(
                List.of(new
BitSetAttributeSimilarityCalculator(List.of(BinarySimilarity.JACCARD_SIMILARITY))));

        final SimilarityVectorFlattener flattener = new BaseSimilarityVectorFlattener(
                List.of(DoubleListAggregator.FIRST));
        final FlatSimilarityVectorAggregator aggregator = new BaseSimilarityVectorAggregator(
                DoubleListAggregator.FIRST);
        final SimilarityVectorAggregator agg = new SimilarityVectorAggregator(flattener,
aggregator);


        final Classificator classifier = new ThresholdClassificator(threshold, agg);

        final MatchStrategyFactory<Record> matchFactory = new
SimilarityGraphMatchStrategyFactory<>();
        final NonMatchStrategyFactory<Record> nonMatchFactory = new
IgnoreNonMatchesStrategyFactory<>();
        final LinkageResultPartitionFactory<Record> linkResFac = new
LinkageResultPartitionFactory<>(matchFactory, nonMatchFactory);
        final SimilarityClassification simClass = new BatchSimilarityClassification(compStrat,
simCalc, classifier,
                RedundancyCheckStrategy.MATCH_TWICE, linkResFac);
        final ThresholdClassificationRefinement threshRef = new
StandardThresholdClassificationRefinement();

        final PostprocessingStrategy<Record> postprocessor = new PostprocessingStrategy<>();
        postprocessor.setPostprocessor(LinkageConstraint.ONE_TO_ONE, new
MaxBothPostprocessor<Record>());
        postprocessor.setPostprocessor(LinkageConstraint.MANY_TO_ONE, new
MaxRightPostprocessor<Record>());
        postprocessor.setPostprocessor(LinkageConstraint.ONE_TO_MANY, new
NoPostprocessor<Record>());
        postprocessor.setPostprocessor(LinkageConstraint.MANY_TO_MANY, new
NoPostprocessor<Record>());

        final Matcher<Record> matcher = new BatchMatcher(blocker, simClass, threshRef,
postprocessor);

        final LinkageResult<Record> linkRes = matcher.match(input);

        final TrueMatchChecker trueMatchChecker = new IdEqualityTrueMatchChecker();
        final QualityEvaluator<Record> evaluator = new QualityEvaluator<>(trueMatchChecker);

        final PartyPair partyPairAB = new PartyPair(new Party(namePartyA), new Party(namePartyB));
```

```
        final LinkageResultPartition<Record> part = linkRes.getPartition(partyPairAB);
        evaluator.addMatches(part.getMatchStrategy().getMatches());


        final long truePos = evaluator.getTruePositives();
        final long falsePos = evaluator.getFalsePositives();

        final double recall = QualityMetrics.getRecall(truePos, matches);
        final double precision = QualityMetrics.getPrecision(truePos, truePos + falsePos);
        final double fmeasure = QualityMetrics.getFMeasure(recall, precision);

        System.out.println("Recall: " + recall);
        System.out.println("Precision: " + precision);
        System.out.println("F-Measuer: " + fmeasure);

    }
```

4.2 Risultati raggiunti

Esempio 1

Input

Dataset A: 20 record
Dataset B: 20 record

Esempio:

id,	fname,	gname,	address,	dob
0,	Dimitrios,	Huebner,	81379 Muenchen,	17.12.1974
1,	Ruth,	Schroeder,	42899 Remscheid,	11.06.1953

Data Cleaning

- Accent Remover
- Special Character Remover
- Lower Case Normalizer
- UmlautNormalizer
- TrimNormalizer

Test

- Funzione di Similarità: Jaccard Similarity
  Threshold: 0.7

  True Positive (TP): 20
  False Positive (FP): 0
  Precision: 1
  Recall: 1
  F-measure: 1
  Match completati correttamente: 20 / 20

- Funzione di Similarità: Jaccard Similarity
  Threshold: 0.8

  True Positive (TP): 18
  False Positive (FP): 0
  Precision: 1
  Recall: 0.9
  F-measure: 0.9474
  Match completati correttamente: 18 / 20

- Funzione di Similarità: Dice Similarity
  Threshold: 0.8

  True Positive (TP): 20
  False Positive (FP): 0
  Precision: 1
  Recall: 1
  F-measure: 1
  Match completati correttamente: 20 / 20

Esempio 2

Input

Dataset A: 5000 record
Dataset B: 5000 record

Esempio:
rec_id, given_name, surname, street_number, address_1, address_2, suburb, postcode, state, date_of_birth, soc_sec_id
rec-1070-org, michaela, neumann, 8, stanley street, miami, winston hills, 4223, nsw, 19151111, 5304218
rec-1016-org, courtney, painter, 12, pinkerton circuit, bega flats, richlands, 4560, vic, 19161214, 4066625

Data Cleaning

- Accent Remover
- Special Character Remover
- Lower Case Normalizer
- Umlaut Normalizer
- Trim Normalizer

Test

- Funzione di Similarità: Jaccard Similarity
  Threshold: 0.8

  True Positive (TP): 4950
  False Positive (FP): 50
  Precision: 0.9990
  Recall: 1
  F-measure: 0.9994
  Match completati correttamente: 4950 / 5000

Dataset A	Dataset B	Similarity
rec-3768-org, UWSlpZfjaKaIMAY...	rec-3768-org, UWSlpZfjaKaIMAY...	0.9358024691358025
rec-4887-org, kRQRo6/nbbOaNj...	rec-4887-org, kRVxo6/nbbOaNj...	0.9321663019693655
rec-1688-org, gT4E4IfiSSKYPHH...	rec-1688-org, gT4E4IfiSSaYPHH...	0.9395465994962217
rec-4065-org, gPAAoUiEZJAYAC...	rec-4065-org, gPAAociEZJQYAC...	0.8498402555910544
rec-85-org, 1XQiFce4baDZKCZiA...	rec-85-org, 1XQiFcf4baDZaCZiAI...	0.9232613908872902
rec-3119-org, kKwAJCuiaADIJG...	rec-3119-org, krwAJCumaADIZ...	0.898936170212766
rec-4238-org, wRQDsYtgygjKLG...	rec-4238-org, wRUDsYtgygjKLG...	0.9420654911838791

- Funzione di Similarità: Dice Similarity
  Threshold: 0.8

  True Positive (TP): 4950
  False Positive (FP): 50
  Precision: 0.9990
  Recall: 1
  F-measure: 0.9994
  Match completati correttamente: 4950 / 5000

4.3 Applicazione basata su PRIMAT

Esiste anche una versione grafica di PRIMAT (PRIMAT Application: https://github.com/gen-too/primat).

Data Owner APP

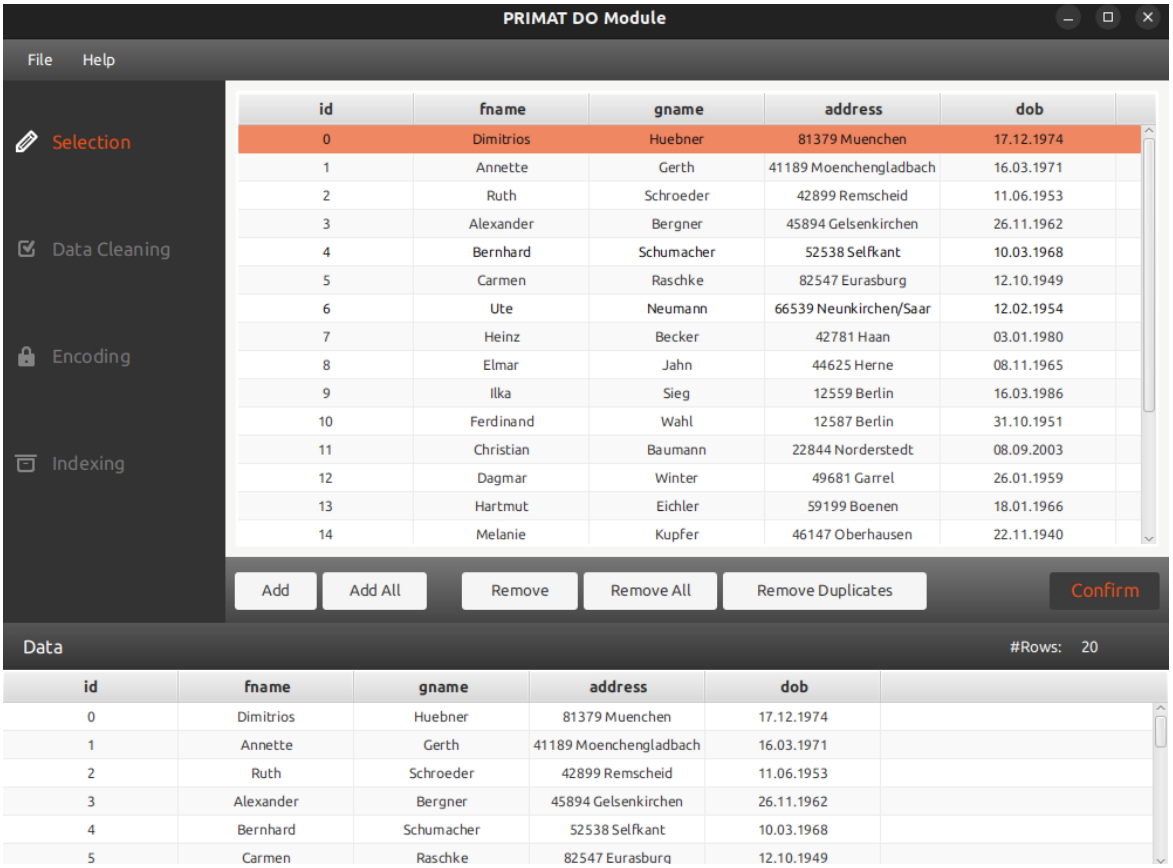

Linkage Unit APP

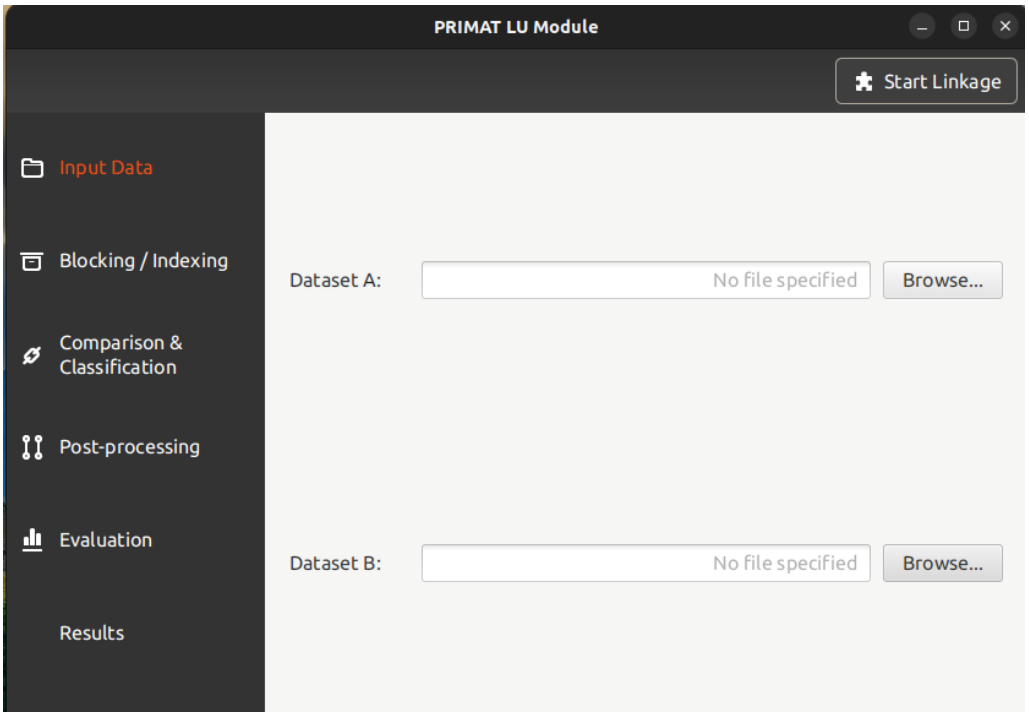

5. Custom PPRL

Esempio 3

In questo esempio provo a costruire uno schema di PPRL in maniera custom, simulando un caso con Data Frame dirty-dirty.

LOAD DATASETS: Esempio 3

```
[72]  1 datasetName = "dataset_febrl3.csv"
      2
      3 Table = pd.read_csv(datasetName, encoding = 'unicode_escape').astype('string')
      4 Table['id']=Table['rec_id']
```

```
[90]  1 Table
```

	rec_id	given_name	surname	address_1	address_2	suburb	postcode	state	date_of_birth	soc_sec_id	id
0	rec-1496-org	mitchell	green	wallaby place	delmar	cleveland	2119	sa	19560409.0	1804974	rec-1496-org
1	rec-552-dup-3	harley	mccarthy	pridhamstreet	milton	marsden	3165	nsw	19080419.0	6089216	rec-552-dup-3
2	rec-988-dup-1	madeline	mason	hoseason street	lakefront retrmnt vlge	granville	4881	nsw	19081128.0	2185997	rec-988-dup-1
3	rec-1716-dup-1	isabelle	<NA>	gundulu place	currin ga	utakarra	2193	wa	19921119.0	4314184	rec-1716-dup-1
4	rec-1213-org	taylor	hathaway	yuranigh court	brentwood vlge	<NA>	4220	nsw	19991207.0	9144092	rec-1213-org

CUSTOM PPRL: Esempio 3

```
# costruisco DA e DB simulando dirty-dirty
DA=Table[(Table['rec_id'].str.endswith('org'))]
DB=Table[(Table['rec_id'].str.endswith('0'))]

DA['id']= DA['id'].map(preprocess_title)
DA.id = DA.id.astype(int)
DA = DA.sort_values('id')
DA.id = DA.id.astype('string')

DB['id']= DB['id'].map(preprocess_title)
DB.id = DB.id.astype(int)
DB = DB.sort_values('id')
DB.id = DB.id.astype('string')

DA.shape[0],DB.shape[0],DA.shape[0]+DB.shape[0]
```

```
[91]  DA
```

	rec_id	given_name	surname	address_1	address_2	suburb	postcode	state	date_of_birth	soc_sec_id	id	mix	
3419	rec-0-org	jinni	dreyer	were street	marriott downs	south melbourne	3172	nsw	19420127.0	3787407	0	jinni dreyer were street marriott downs south melbourne 3172 nsw 19420127.0 3787407	351167847528913316233
2440	rec-2-org	mia	thredgold	summerland circuit	cornvale	highett	5110	vic	19980406.0	7484089	2	mia thredgold summerland circuit cornvale highett 5110 vic	1437367195260495

```
### ENCODE TABLE A

DA.drop_duplicates(DA.columns[1:3], keep='first', inplace=True) #Index(['given_name', 'surname'], dtype='object')

for col in DA.columns[1:10]:
  DA = DA[DA[col].notna()]

mixColumnsA = DA.columns[1:10] #Index(['given_name', 'surname', 'address_1', 'address_2', 'suburb', 'postcode','state', 'date_of_birth', 'soc_sec_id'],dtype='object')
DA['mix'] = ' '

for x in list(mixColumnsA) :
  DA['mix'] += DA[x] + ' '

DA['bf'] = DA.apply(lambda row: ApplyBloomFilter(row), axis=1)

DA_ENC = DA[[DA.columns[len(DA.columns)-3],DA.columns[len(DA.columns)-1]]]  # DA encoded : ('id', 'bf')


### ENCODE TABLE B

DB.drop_duplicates(DB.columns[1:3], keep='first', inplace=True) #Index(['given_name', 'surname'], dtype='object')

for col in DB.columns[1:10]:
  DB = DB[DB[col].notna()]

mixColumnsB = DB.columns[1:10] #Index(['given_name', 'surname', 'address_1', 'address_2', 'suburb', 'postcode','state', 'date_of_birth', 'soc_sec_id'],dtype='object')
DB['mix'] = ' '

for x in list(mixColumnsB) :
  DB['mix'] += DB[x] + ' '

DB['bf'] = DB.apply(lambda row: ApplyBloomFilter(row), axis=1)

DB_ENC = DB[[DB.columns[len(DB.columns)-3],DB.columns[len(DB.columns)-1]]]  # DB encoded : ('id', 'bf')
```

```
DA_ENC
```

	id	bf
3419	0	351167847528913316233668275860303369455417171499818813840934454120926237466954393643630472315210...
2440	2	143736719526049598875550040685046846060410828649454505883816101531766881991785204814262285791983...
4804	3	294935825683194405579415722808547437322455756041110171495444291077748801679710359549573436747340...
213	4	182912520715152883230887209182041464653592245991682425619368197402940102622251004244511994973773...
312	5	143257757406442456129658248986491260990211573409582754168679113213897632259264643292900858992898...
...	...	...

```
[76]  PCC_ENC = DA_ENC.assign(key=1).merge(DB_ENC.assign(key=1), on='key', suffixes=('_l', '_r')).drop('key', 1)
      PCC_ENC['bf_sim'] = PCC_ENC.apply (lambda row: Funzione_J_hat_from_bf(row), axis=1)
```

```
<ipython-input-76-814d5d15db7f>:1: FutureWarning: In a future version of pandas all arguments of DataFrame.drop except for the argument 'labels' will be keyword-only
  PCC_ENC = DA_ENC.assign(key=1).merge(DB_ENC.assign(key=1), on='key', suffixes=('_l', '_r')).drop('key', 1)
```

```
PCC_ENC
```

	id_l	bf_l	id_r	
0	0	351167847528913316233668275860303369455417171499818813840934454120926237466954393643630472315210...	3	2949358273574266043079554377566446209125825
1	0	351167847528913316233668275860303369455417171499818813840934454120926237466954393643630472315210...	5	1432583015319070429060321681086972781656375
2	0	351167847528913316233668275860303369455417171499818813840934454120926237466954393643630472315210...	10	7132647070802814463345442106701066862751404
3	0	351167847528913316233668275860303369455417171499818813840934454120926237466954393643630472315210...	12	1432947243878325655912114987686388663888417
4	0	351167847528913316233668275860303369455417171499818813840934454120926237466954393643630472315210...	14	1438569964985722190249186669884972061596705
...	...	...	...	

```
[78] 1 SM_J_sim = StableMarriage(PCC_ENC[['id_l', 'id_r','bf_sim']])
```

```
1 SM_J_sim
```

	rec_id_l	rec_id_r	sim
0	1484	1484	1.000000
1	1316	1316	1.000000
2	1479	1479	1.000000
3	1009	1009	1.000000
4	960	960	1.000000
...	...	...	...
808	942	666	0.412742
809	1115	534	0.405556
810	664	1910	0.398892
811	776	324	0.383954
812	1587	258	0.379603

813 rows × 3 columns

```
[87] 1 GoldStandard = pd.DataFrame({'l_id': DA['id'], 'r_id': DA['id']})
     2 SM_J_sim_Evaluation = SM_J_sim[['rec_id_l','rec_id_r']].rename(columns={'rec_id_l':'l_id','rec_id_r':'r_id'})
```

```
1 Evaluation(GoldStandard, SM_J_sim_Evaluation)
```

	MT	TP	FP	FN	P	R	F
0	813	787	26	843	0.968	0.4828	0.6443

6. References

- Scientific paper: Privacy Preserving Record Linkage (Rainer Schnell)
- Scientific paper: PRIMAT: A Toolbox for Fast Privacy-preserving Matching (Martin Franke, Ziad Sehili, Erhard Rahm)
- PRIMAT: https://git.informatik.uni-leipzig.de/dbs/pprl/primat
- PRIMAT Application: https://github.com/gen-too/primat
- https://www.boozallen.com/insights/ai/privacy-preserving-record-linkage.html
- https://www.sciencedirect.com/science/article/abs/pii/S0306437921001526
- https://github.com/data61/anonlink-entity-service
- https://github.com/DuncanSmith147/pseudonymization

- Codice progetto + Tesina + Presentazione: https://github.com/mariocris/SIWS.git